

3.3 Inversa de una función convexa y creciente

Problema: Suponga que $f : \mathbf{R} \rightarrow \mathbf{R}$ es creciente y convexa en su dominio (a, b) . Sea g su inversa, es decir, la función con dominio $(f(a), f(b))$ tal que $g(f(x)) = x$. ¿Qué se puede decir sobre la convexidad o concavidad de g ?

Respuesta: La función g es **cóncava**.

Demostración (Prueba de la segunda derivada)

Para demostrar esto rigurosamente, asumimos que f es dos veces diferenciable.

1. **Propiedades dadas de f :**

- f es creciente $\implies f'(x) > 0$
- f es convexa $\implies f''(x) \geq 0$

2. **Paso 1: Primera derivada de g**

Sabemos que $f(g(y)) = y$. Derivamos ambos lados respecto a y usando la regla de la cadena:

$$f'(g(y)) \cdot g'(y) = 1$$

Despejando $g'(y)$:

$$g'(y) = \frac{1}{f'(g(y))} \quad (1)$$

(Nota: Como $f'(x) > 0$, entonces $g'(y) > 0$, lo que confirma que la inversa también es creciente).

3. **Paso 2: Segunda derivada de g**

Derivamos la ecuación (1) respecto a y utilizando la regla de la cadena y la regla del cociente:

$$\begin{aligned} g''(y) &= \frac{d}{dy} \left(\frac{1}{f'(g(y))} \right) \\ g''(y) &= -\frac{1}{[f'(g(y))]^2} \cdot \frac{d}{dy} (f'(g(y))) \\ g''(y) &= -\frac{1}{[f'(g(y))]^2} \cdot f''(g(y)) \cdot g'(y) \end{aligned}$$

Sustituimos el valor de $g'(y)$ de la ecuación (1):

$$\begin{aligned} g''(y) &= -\frac{f''(g(y))}{[f'(g(y))]^2} \cdot \frac{1}{f'(g(y))} \\ g''(y) &= -\frac{f''(g(y))}{[f'(g(y))]^3} \end{aligned}$$

4. Paso 3: Análisis del signo

Analicemos los componentes de la fracción:

- El numerador $f''(g(y)) \geq 0$ (porque f es convexa).
- El denominador $[f'(g(y))]^3 > 0$ (porque f es creciente, f' es positivo y un positivo al cubo sigue siendo positivo).
- Hay un signo **negativo** multiplicando la fracción.

Por lo tanto:

$$g''(y) \leq 0$$

Conclusión: Dado que la segunda derivada es menor o igual a cero, la función inversa g es **cóncava**.

3.6 Funciones y Epígraficas

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$. El epígrafe se define como:

$$\text{epi}(f) = \{(x, t) \in \mathbb{R}^{n+1} \mid f(x) \leq t\}$$

1. ¿Cuándo es el epígrafe un semiespacio?

El epígrafe es un semiespacio si y solo si la función f es **afín**.

$$f(x) = a^T x + b$$

2. ¿Cuándo es el epígrafe un cono convexo?

El epígrafe es un cono convexo si y solo si f es **convexa y positivamente homogénea** (de grado 1).

$$f(\lambda x) = \lambda f(x), \quad \forall \lambda > 0$$

3. ¿Cuándo es el epígrafe un poliedro?

El epígrafe es un poliedro si y solo si f es una función **convexa lineal a trozos** (piecewise-linear) con dominio poliédrico. Esto equivale a decir que f es el máximo de un conjunto finito de funciones afines:

$$f(x) = \max_{i=1, \dots, k} (a_i^T x + b_i)$$

3.7 Función convexa y acotada

Enunciado: Suponga que $f : \mathbf{R}^n \rightarrow \mathbf{R}$ es convexa con $\text{dom} f = \mathbf{R}^n$, y está acotada superiormente en $\mathbf{R}^n$. Demuestre que f es constante.

Sea M la cota superior de f , tal que $f(x) \leq M$ para todo $x \in \mathbf{R}^n$.

Procedemos por contradicción. Supongamos que f no es constante. Entonces, deben existir dos puntos distintos $x, y \in \mathbf{R}^n$ tales que $f(y) \neq f(x)$. Sin pérdida de generalidad, asumamos que:

$$f(y) > f(x)$$

Consideremos un punto z que se encuentra en la recta que pasa por x e y , extendiéndose más allá de y . Podemos expresar z como:

$$z = x + t(y - x) \quad \text{donde } t > 1$$

De esta relación, podemos despejar y como una combinación convexa de x y z :

$$y = \left(1 - \frac{1}{t}\right)x + \frac{1}{t}z$$

Como $t > 1$, los coeficientes $(1 - 1/t)$ y $1/t$ son positivos y suman 1.

Aplicando la definición de convexidad de f :

$$f(y) \leq \left(1 - \frac{1}{t}\right)f(x) + \frac{1}{t}f(z)$$

Nuestro objetivo es despejar $f(z)$ para mostrar que explota hacia el infinito. Multiplicamos toda la inecuación por t :

$$tf(y) \leq (t-1)f(x) + f(z)$$

Reordenamos para aislar $f(z)$:

$$f(z) \geq tf(y) - (t-1)f(x)$$

$$f(z) \geq t(f(y) - f(x)) + f(x)$$

Analicemos el límite cuando $t \rightarrow \infty$:

- Sabemos que la diferencia $f(y) - f(x) > 0$ por nuestra suposición inicial.
- Por lo tanto, el término $t(f(y) - f(x))$ tiende a $+\infty$ cuando t crece.
- Esto implica que $f(z)$ puede hacerse arbitrariamente grande eligiendo un t suficientemente grande.

Específicamente, podemos elegir un t tal que $f(z) > M$, lo cual contradice la hipótesis de que f está acotada superiormente por M .

Por lo tanto, la suposición de que $f(y) > f(x)$ debe ser falsa. Por simetría, $f(x) > f(y)$ también es falso.

Concluimos que $f(x) = f(y)$ para cualesquiera $x, y \in \mathbf{R}^n$, lo que significa que f es constante.

3.8

Demuestre que una función dos veces diferenciable f es convexa si y solo si su dominio es convexo y $\nabla^2 f(x) \succeq 0$ para todo $x \in \text{dom } f$.

Demostración

La demostración se basa en reducir la función multivariable a una función de una sola variable restringiéndola a una línea arbitraria.

Paso 1: Reducción a una variable

Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es convexa si y solo si es convexa cuando se restringe a cualquier línea que intersecte su dominio.

Sean $x \in \text{dom } f$ y $v \in \mathbb{R}^n$ un vector arbitrario. Definimos la función escalar $g : \mathbb{R} \rightarrow \mathbb{R}$ como:

$$g(t) = f(x + tv)$$

donde el dominio de g es el conjunto $\{t \mid x + tv \in \text{dom } f\}$.

Sabemos que f es convexa si y solo si $g(t)$ es convexa para todo x y todo v .

Paso 2: Derivadas de la restricción

Calculamos la primera y segunda derivada de $g(t)$ utilizando la regla de la cadena multivariable.

Primera derivada $g'(t)$:

$$g'(t) = \nabla f(x + tv)^T v$$

Segunda derivada $g''(t)$: Derivamos nuevamente respecto a t :

$$g''(t) = \frac{d}{dt} \left(\sum_{i=1}^n \frac{\partial f}{\partial x_i}(x + tv) \cdot v_i \right)$$
$$g''(t) = \sum_{i=1}^n \left(\sum_{j=1}^n \frac{\partial^2 f}{\partial x_i \partial x_j}(x + tv) \cdot v_j \right) v_i$$

En notación matricial, esto es:

$$g''(t) = v^T \nabla^2 f(x + tv) v$$

Paso 3: Aplicación de la condición en 1D

Para una función escalar dos veces diferenciable, sabemos que es convexa si y solo si su segunda derivada es no negativa ($g''(t) \geq 0$).

- **Suficiencia** ($\Leftarrow$): Supongamos que la matriz Hessiana es semidefinida positiva ($\nabla^2 f(x) \succeq 0$) para todo x . Esto implica que para cualquier vector v , la forma cuadrática es no negativa:

$$v^T \nabla^2 f(x + tv)v \geq 0$$

Por lo tanto, $g''(t) \geq 0$. Esto significa que g es convexa para cualquier línea, lo que implica que f es convexa.

- **Necesidad** ($\Rightarrow$): Supongamos que f es convexa. Entonces g debe ser convexa, lo que implica que $g''(t) \geq 0$ para todo t en el dominio. Evaluando en $t = 0$:

$$g''(0) = v^T \nabla^2 f(x)v \geq 0$$

Como esto debe cumplirse para cualquier vector $v \in \mathbb{R}^n$, concluimos por definición que la matriz Hessiana $\nabla^2 f(x)$ debe ser semidefinida positiva ($\nabla^2 f(x) \succeq 0$).

Conclusión

Hemos demostrado que f es convexa si y solo si $\nabla^2 f(x)$ es semidefinida positiva en todo su dominio.

$f \text{ es convexa} \iff \nabla^2 f(x) \succeq 0, \quad \forall x \in \text{dom } f$
--

3.11

Una función $\psi : \mathbf{R}^n \rightarrow \mathbf{R}$ se llama *monótona* si para todo $x, y \in \text{dom } \psi$:

$$(\psi(x) - \psi(y))^T (x - y) \geq 0$$

Suponga que $f : \mathbf{R}^n \rightarrow \mathbf{R}$ es una función convexa diferenciable.

1. Demuestre que su gradiente ∇f es monótono.
2. ¿Es cierto el converso? Es decir, ¿es todo mapeo monótono el gradiente de una función convexa?

Solución

1. Demostración: Convexidad implica Gradiente Monótono

Usamos la condición de primer orden para funciones convexas. Si f es convexa y diferenciable, para cualesquiera dos puntos $x, y \in \text{dom } f$ se cumple:

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) \tag{2}$$

Intercambiando x e y , también se cumple:

$$f(x) \geq f(y) + \nabla f(y)^T(x - y) \quad (3)$$

Sumamos las desigualdades (2) y (3):

$$f(y) + f(x) \geq f(x) + \nabla f(x)^T(y - x) + f(y) + \nabla f(y)^T(x - y)$$

Cancelamos $f(x)$ y $f(y)$ de ambos lados:

$$0 \geq \nabla f(x)^T(y - x) + \nabla f(y)^T(x - y)$$

Recordemos que $(y - x) = -(x - y)$. Sustituimos esto en el primer término:

$$0 \geq -\nabla f(x)^T(x - y) + \nabla f(y)^T(x - y)$$

Reorganizamos pasando el término negativo al lado izquierdo:

$$\nabla f(x)^T(x - y) - \nabla f(y)^T(x - y) \geq 0$$

Factorizamos $(x - y)$:

$$(\nabla f(x) - \nabla f(y))^T(x - y) \geq 0$$

Esta es exactamente la definición de un mapeo monótono para $\psi = \nabla f$.

2. El Converso

Respuesta: No, el converso no es cierto.

Para que un mapeo $\psi : \mathbf{R}^n \rightarrow \mathbf{R}^n$ sea el gradiente de alguna función escalar f (es decir, $\psi = \nabla f$), la matriz Jacobiana de ψ debe ser ****simétrica**** (debido al teorema de simetría de las segundas derivadas, $\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$).

Sin embargo, la definición de monotonía no requiere simetría, solo que la parte simétrica del Jacobiano sea semidefinida positiva.

Considere el mapeo lineal $\psi(x) = Ax$ con la matriz:

$$A = \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}$$

Verificamos si es monótono:

$$(\psi(x) - \psi(y))^T(x - y) = (Ax - Ay)^T(x - y) = (x - y)^T A(x - y)$$

Sea $v = x - y$. Calculamos $v^T Av$:

$$\begin{aligned} \begin{pmatrix} v_1 & v_2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} &= \begin{pmatrix} v_1 & v_2 \end{pmatrix} \begin{pmatrix} v_1 + v_2 \\ -v_1 + v_2 \end{pmatrix} \\ &= v_1(v_1 + v_2) + v_2(-v_1 + v_2) = v_1^2 + v_1 v_2 - v_1 v_2 + v_2^2 = v_1^2 + v_2^2 \geq 0 \end{aligned}$$

Por lo tanto, ψ es **monótono**.

Sin embargo, la matriz A no es simétrica ($a_{12} \neq a_{21}$). Por lo tanto, ψ no puede ser el gradiente de ninguna función escalar f .

3.12 Separación de Funciones Convexa y Cóncava

Suponga que $f : \mathbf{R}^n \rightarrow \mathbf{R}$ es convexa, $g : \mathbf{R}^n \rightarrow \mathbf{R}$ es cóncava, $\text{dom } f = \text{dom } g = \mathbf{R}^n$, y para todo x , $g(x) \leq f(x)$. Demuestre que existe una función afín h tal que para todo x , $g(x) \leq h(x) \leq f(x)$.

La prueba se basa en el teorema del hiperplano separador aplicado a los conjuntos geométricos definidos por las funciones en $\mathbf{R}^{n+1}$.

1. Definición de Conjuntos Convexos

Definimos dos subconjuntos de $\mathbf{R}^{n+1}$:

- El epígrafe de f :

$$C_1 = \text{epi}(f) = \{(x, t) \in \mathbf{R}^n \times \mathbf{R} \mid f(x) \leq t\}$$

Dado que f es convexa, C_1 es un conjunto convexo.

- El hipógrafo de g :

$$C_2 = \text{hypo}(g) = \{(x, t) \in \mathbf{R}^n \times \mathbf{R} \mid g(x) \geq t\}$$

Dado que g es cóncava, C_2 es un conjunto convexo.

2. Separación de Conjuntos

La condición dada $g(x) \leq f(x)$ implica que el interior de C_1 y el interior de C_2 son disjuntos. Específicamente, no existe ningún punto (x, t) que esté estrictamente por encima de f y estrictamente por debajo de g simultáneamente.

Por el **Teorema del Hiperplano Separador**, existe un vector no nulo $(\mu, \lambda) \in \mathbf{R}^n \times \mathbf{R}$ y un escalar $\gamma \in \mathbf{R}$ tal que el hiperplano definido por (μ, λ) separa C_1 y C_2 :

$$\mu^T x + \lambda t \geq \gamma \quad \forall (x, t) \in C_1 \tag{4}$$

$$\mu^T x + \lambda t \leq \gamma \quad \forall (x, t) \in C_2 \tag{5}$$

3. Análisis del Escalar λ

Debemos demostrar que $\lambda > 0$ para poder despejar t y formar una función.

- Si $\lambda < 0$: En C_1 podemos tomar $t \rightarrow \infty$ (pues si $(x, t) \in C_1$, entonces $(x, t + k) \in C_1$ para $k > 0$). Si $\lambda < 0$, el término λt tendería a $-\infty$, violando la desigualdad (4). Por lo tanto, $\lambda \geq 0$.
- Si $\lambda = 0$: Las desigualdades se convierten en $\mu^T x \geq \gamma$ para todo $x \in \text{dom } f$ y $\mu^T x \leq \gamma$ para todo $x \in \text{dom } g$. Como los dominios son todo $\mathbf{R}^n$, la única forma de que un funcional lineal esté acotado superior e inferiormente en todo el espacio es que el vector sea cero ($\mu = 0$). Pero el teorema separador garantiza que $(\mu, \lambda) \neq (0, 0)$. Por lo tanto, $\lambda \neq 0$.

Concluimos que $\lambda > 0$.

4. Construcción de $h(x)$

Como $\lambda > 0$, podemos dividir las desigualdades por λ . De (4), tomando puntos en la frontera donde $t = f(x)$:

$$\mu^T x + \lambda f(x) \geq \gamma \implies f(x) \geq \frac{\gamma - \mu^T x}{\lambda}$$

De (5), tomando puntos en la frontera donde $t = g(x)$:

$$\mu^T x + \lambda g(x) \leq \gamma \implies g(x) \leq \frac{\gamma - \mu^T x}{\lambda}$$

Definimos la función afín $h(x)$ como:

$$h(x) = \frac{\gamma}{\lambda} - \frac{1}{\lambda} \mu^T x$$

(Lo cual tiene la forma $a^T x + b$).

Combinando los resultados anteriores, obtenemos:

$$g(x) \leq h(x) \leq f(x)$$

3.13 Divergencia Kullback-Leibler y la Desigualdad de la Información

Sea D_{kl} la divergencia de Kullback-Leibler. Demuestre la *desigualdad de la información*: $D_{kl}(u, v) \geq 0$ para todo $u, v \in \mathbf{R}_{++}^n$. También demuestre que $D_{kl}(u, v) = 0$ si y solo si $u = v$.

Pista: La divergencia se puede expresar como:

$$D_{kl}(u, v) = f(u) - f(v) - \nabla f(v)^T (u - v)$$

donde $f(v) = \sum_{i=1}^n v_i \log v_i$.

La demostración se basa en las propiedades de convexidad de la función $f(v)$.

1. Análisis de Convexidad de $f(v)$

Consideremos la función $f : \mathbf{R}_{++}^n \rightarrow \mathbf{R}$ dada por:

$$f(x) = \sum_{i=1}^n x_i \log x_i$$

Para determinar su convexidad, calculamos su matriz Hessiana $\nabla^2 f(x)$. Primero, encontramos las derivadas parciales. El gradiente $\nabla f(x)$ tiene componentes:

$$\frac{\partial f}{\partial x_k} = \frac{d}{dx_k} (x_k \log x_k) = \log x_k + 1$$

Ahora calculamos las segundas derivadas para el Hessiano:

$$\frac{\partial^2 f}{\partial x_k \partial x_j} = \begin{cases} \frac{1}{x_k} & \text{si } k = j \\ 0 & \text{si } k \neq j \end{cases}$$

Por lo tanto, el Hessiano es una matriz diagonal:

$$\nabla^2 f(x) = \text{diag} \left(\frac{1}{x_1}, \frac{1}{x_2}, \dots, \frac{1}{x_n} \right)$$

Dado que el dominio es $\mathbf{R}_{++}^n$, tenemos que $x_i > 0$ para todo i . En consecuencia, $\frac{1}{x_i} > 0$, lo que implica que la matriz Hessiana es **definida positiva** ($\nabla^2 f(x) \succ 0$) en todo el dominio.

Esto demuestra que $f(x)$ es una función **estrictamente convexa**.

2. Aplicación de la Condición de Primer Orden

La condición de primer orden para funciones convexas establece que f es convexa si y solo si su gráfica siempre está por encima de su tangente (o aproximación de primer orden). Matemáticamente:

$$f(u) \geq f(v) + \nabla f(v)^T(u - v)$$

Además, como f es *estrictamente* convexa, la igualdad se cumple si y solo si $u = v$.

3. Conclusión

Reordenamos la desigualdad de convexidad:

$$f(u) - f(v) - \nabla f(v)^T(u - v) \geq 0$$

Observamos que el lado izquierdo de esta expresión es exactamente la definición dada en la pista para la divergencia Kullback-Leibler. Por lo tanto:

$$D_{kl}(u, v) \geq 0$$

Debido a la convexidad estricta de f , la igualdad $D_{kl}(u, v) = 0$ se mantiene si y solo si $u = v$.

3.17 Concavidad de la p -norma para $p < 1$

Suponga que $p < 1, p \neq 0$. Demuestre que la función

$$f(x) = \left(\sum_{i=1}^n x_i^p \right)^{1/p}$$

con $\text{dom } f = \mathbf{R}_{++}^n$ es cóncava.

Para demostrar que f es cóncava, calcularemos su matriz Hessiana $\nabla^2 f(x)$ y demostraremos que es semidefinida negativa ($\nabla^2 f(x) \preceq 0$) en todo su dominio.

1. Primera Derivada (Gradiente)

Sea $S = \sum_{k=1}^n x_k^p$. Entonces $f(x) = S^{1/p}$. Calculamos la derivada parcial respecto a x_i :

$$\frac{\partial f}{\partial x_i} = \frac{1}{p} S^{\frac{1}{p}-1} \cdot \frac{\partial S}{\partial x_i}$$

Como $\frac{\partial S}{\partial x_i} = p x_i^{p-1}$, tenemos:

$$\frac{\partial f}{\partial x_i} = S^{\frac{1}{p}-1} x_i^{p-1}$$

Podemos reescribir esto en términos de $f(x)$ notando que $S = f(x)^p$:

$$\frac{\partial f}{\partial x_i} = f(x)^{1-p} x_i^{p-1} \quad (6)$$

2. Segunda Derivada (Hessiano)

Derivamos (6) respecto a x_j para encontrar los componentes de la Hessiana $\nabla^2 f(x)_{ij}$.

Caso $i \neq j$:

$$\begin{aligned} \frac{\partial^2 f}{\partial x_i \partial x_j} &= \frac{\partial}{\partial x_j} \left(f(x)^{1-p} x_i^{p-1} \right) \\ &= (1-p) f(x)^{-p} \frac{\partial f}{\partial x_j} x_i^{p-1} \end{aligned}$$

Sustituyendo $\frac{\partial f}{\partial x_j}$:

$$\begin{aligned} &= (1-p) f(x)^{-p} (f(x)^{1-p} x_j^{p-1}) x_i^{p-1} \\ &= (1-p) f(x)^{1-2p} x_i^{p-1} x_j^{p-1} \end{aligned}$$

Caso $i = j$: Usamos la regla del producto:

$$\begin{aligned} \frac{\partial^2 f}{\partial x_i^2} &= (1-p) f(x)^{-p} \frac{\partial f}{\partial x_i} x_i^{p-1} + f(x)^{1-p} (p-1) x_i^{p-2} \\ &= (1-p) f(x)^{1-2p} x_i^{2(p-1)} - (1-p) f(x)^{1-p} x_i^{p-2} \end{aligned}$$

3. Análisis de la Forma Cuadrática

Sea $v \in \mathbf{R}^n$ un vector arbitrario. Analizamos el signo de $v^T \nabla^2 f(x) v$:

$$v^T \nabla^2 f(x) v = \sum_{i,j} v_i v_j \frac{\partial^2 f}{\partial x_i \partial x_j}$$

Agrupando los términos, podemos factorizar $(1-p)f(x)^{1-2p}$:

$$v^T \nabla^2 f(x) v = (1-p)f(x)^{1-2p} \left[\left(\sum_{i=1}^n x_i^{p-1} v_i \right)^2 - f(x)^p \sum_{i=1}^n x_i^{p-2} v_i^2 \right]$$

Recordemos que $f(x)^p = \sum_{k=1}^n x_k^p$. Sustituimos esto en la expresión:

$$v^T \nabla^2 f(x) v = (1-p)f(x)^{1-2p} \underbrace{\left[\left(\sum_{i=1}^n x_i^{p-1} v_i \right)^2 - \left(\sum_{k=1}^n x_k^p \right) \left(\sum_{i=1}^n x_i^{p-2} v_i^2 \right) \right]}_{\text{Término entre corchetes}}$$

4. Desigualdad de Cauchy-Schwarz

Para analizar el signo del término entre corchetes, definimos dos vectores a y b con componentes:

$$a_i = x_i^{p/2}, \quad b_i = x_i^{p/2-1} v_i$$

Notamos las siguientes identidades:

- $\sum a_i^2 = \sum x_i^p$
- $\sum b_i^2 = \sum x_i^{p-2} v_i^2$
- $\sum a_i b_i = \sum x_i^{p/2} x_i^{p/2-1} v_i = \sum x_i^{p-1} v_i$

La desigualdad de Cauchy-Schwarz establece que $(\sum a_i b_i)^2 \leq (\sum a_i^2)(\sum b_i^2)$. Esto implica directamente que el término entre corchetes es **menor o igual a cero**.

5. Conclusión

Analicemos los signos finales:

- $(1-p) > 0$ dado que $p < 1$.
- $f(x)^{1-2p} > 0$ dado que $x \in \text{dom } f$.
- El término de Cauchy-Schwarz ≤ 0 .

Por lo tanto, $v^T \nabla^2 f(x) v \leq 0$ para todo v . Esto significa que la matriz Hessiana es semidefinida negativa, lo cual demuestra que $f(x)$ es **cóncava**.

3.18

Adapte la prueba de concavidad de la función log-determinante para demostrar lo siguiente:

- (a) $f(X) = (X^{-1})$ es convexa en $f = \mathbf{S}_{++}^n$.
- (b) $f(X) = (\det X)^{1/n}$ es cóncava en $f = \mathbf{S}_{++}^n$.

Solución

La estrategia general es restringir la función f a una línea arbitraria que interseque el dominio. Sea $X \in \mathbf{S}_{++}^n$ y $V \in \mathbf{S}^n$. Definimos la función escalar:

$$g(t) = f(X + tV)$$

El dominio de g es el intervalo de t tal que $X + tV \succ 0$. Para simplificar la expresión, factorizamos $X^{1/2}$:

$$X + tV = X^{1/2}(I + tX^{-1/2}VX^{-1/2})X^{1/2}$$

Sea $Y = X^{-1/2}VX^{-1/2}$. Sea $\lambda_1, \dots, \lambda_n$ los valores propios de Y . Entonces, los valores propios de $I + tY$ son $1 + t\lambda_i$.

Parte (a): $f(X) = (X^{-1})$ es convexa

Evaluamos f en la línea:

$$g(t) = ((X + tV)^{-1}) = \left(\left[X^{1/2}(I + tY)X^{1/2} \right]^{-1} \right)$$

$$g(t) = \left(X^{-1/2}(I + tY)^{-1}X^{-1/2} \right)$$

Usando la propiedad cíclica de la traza $((ABC) = (BCA))$:

$$g(t) = (X^{-1}(I + tY)^{-1})$$

Sea $Y = Q\Lambda Q^T$ la descomposición espectral de Y , donde $\Lambda = \text{diag}(\lambda_i)$. Entonces $(I + tY)^{-1} = Q(I + t\Lambda)^{-1}Q^T$.

$$g(t) = \left(X^{-1}Q\text{diag}\left(\frac{1}{1 + t\lambda_i}\right)Q^T \right)$$

$$g(t) = \left(Q^T X^{-1}Q\text{diag}\left(\frac{1}{1 + t\lambda_i}\right) \right)$$

Definimos la matriz $M = Q^T X^{-1}Q$. Dado que X^{-1} es definida positiva, M también es definida positiva, por lo que sus elementos diagonales son estrictamente positivos ($M_{ii} > 0$). La traza se reduce a la suma de los productos diagonales:

$$g(t) = \sum_{i=1}^n M_{ii} \frac{1}{1 + t\lambda_i}$$

Calculamos la segunda derivada respecto a t :

$$g'(t) = \sum_{i=1}^n M_{ii} \frac{-\lambda_i}{(1 + t\lambda_i)^2}$$

$$g''(t) = \sum_{i=1}^n M_{ii} \frac{2\lambda_i^2}{(1+t\lambda_i)^3}$$

Evaluando en $t = 0$ (donde $1 + t\lambda_i = 1$):

$$g''(0) = \sum_{i=1}^n 2M_{ii}\lambda_i^2$$

Como $M_{ii} > 0$ y $\lambda_i^2 \geq 0$, tenemos que $g''(0) \geq 0$. Por lo tanto, $f(X)$ es **convexa**.

Parte (b): $f(X) = (\det X)^{1/n}$ es **cóncava**

Evaluamos f en la línea:

$$g(t) = (\det(X + tV))^{1/n} = \left(\det(X^{1/2}(I + tY)X^{1/2}) \right)^{1/n}$$

Usando la propiedad multiplicativa del determinante:

$$g(t) = (\det X)^{1/n} (\det(I + tY))^{1/n}$$

$$g(t) = (\det X)^{1/n} \left(\prod_{i=1}^n (1 + t\lambda_i) \right)^{1/n}$$

Esta expresión es proporcional a la **media geométrica** de los valores $1 + t\lambda_i$. Sabemos que la media geométrica $G(y) = (\prod y_i)^{1/n}$ es una función cóncava en $\mathbf{R}_{++}^n$. Como $g(t)$ es la composición de una función cóncava (la media geométrica) con una función afín de t (los términos $1 + t\lambda_i$), concluimos que $g(t)$ es cóncava.

Verificación alternativa con segunda derivada: Sea $h(t) = \log g(t)$. Entonces $g(t) = e^{h(t)}$ y $g''(t) = g(t)(h'(t)^2 + h''(t))$.

$$h(t) = \frac{1}{n} \log \det X + \frac{1}{n} \sum \log(1 + t\lambda_i)$$

$$h'(t) = \frac{1}{n} \sum \frac{\lambda_i}{1 + t\lambda_i}, \quad h''(t) = -\frac{1}{n} \sum \left(\frac{\lambda_i}{1 + t\lambda_i} \right)^2$$

La condición $g''(t) \leq 0$ equivale a $h'(t)^2 + h''(t) \leq 0$:

$$\left(\frac{1}{n} \sum a_i \right)^2 - \frac{1}{n} \sum a_i^2 \leq 0 \quad \text{donde } a_i = \frac{\lambda_i}{1 + t\lambda_i}$$

Esto es cierto por la desigualdad de Cauchy-Schwarz $((\sum a_i)^2 \leq n \sum a_i^2)$. Por lo tanto, $f(X)$ es **cóncava**.

3.37

Demuestre que la conjugada de $f(X) = (X^{-1})$ con $f = \mathbf{S}_{++}^n$ está dada por:

$$f^*(Y) = -2(-Y)^{1/2}, \quad f^* = -\mathbf{S}_{++}^n$$

Pista: El gradiente de f es $\nabla f(X) = -X^{-2}$.

Solución

La función conjugada $f^*(Y)$ se define como el supremo de la función lineal menos la función original:

$$f^*(Y) = \sup_{X \succ 0} ((YX) - (X^{-1})) \quad (7)$$

(Nota: como trabajamos en el espacio de matrices simétricas, el producto interno es $\langle Y, X \rangle = (YX)$).

Para encontrar el supremo, definimos $g(X) = (YX) - (X^{-1})$ y buscamos el punto crítico igualando el gradiente a cero.

1. Cálculo del Gradiente

Derivamos $g(X)$ respecto a la matriz X :

$$\nabla_X g(X) = \nabla_X (YX) - \nabla_X (X^{-1})$$

Sabemos que $\nabla_X (YX) = Y$. Usando la pista proporcionada, $\nabla_X (X^{-1}) = -X^{-2}$. Por lo tanto:

$$\nabla_X g(X) = Y - (-X^{-2}) = Y + X^{-2}$$

2. Condición de Optimalidad y Dominio

Igualemos el gradiente a cero para encontrar el máximo (dado que el problema es cóncavo en X):

$$Y + X^{-2} = 0 \implies X^{-2} = -Y$$

Analicemos las condiciones sobre Y :

- Como $X \in \mathbf{S}_{++}^n$ (simétrica definida positiva), entonces X^{-1} es definida positiva y $X^{-2} = (X^{-1})^2$ también es definida positiva.
- Por lo tanto, para que la ecuación $X^{-2} = -Y$ tenga solución, $-Y$ debe ser definida positiva.
- Esto implica que Y debe ser definida negativa ($Y \prec 0$).

Esto confirma que el dominio de la conjugada es $f^* = -\mathbf{S}_{++}^n$.

3. Despeje de X

A partir de $X^{-2} = -Y$, tomamos la raíz cuadrada matricial (que es única para matrices definidas positivas):

$$X^{-1} = (-Y)^{1/2}$$

Invertimos para encontrar el valor óptimo X^* :

$$X^* = (-Y)^{-1/2}$$

4. Sustitución en la Definición

Sustituimos X^* en la ecuación (7):

$$f^*(Y) = (YX^*) - ((X^*)^{-1})$$

Sustituyendo $X^* = (-Y)^{-1/2}$ y $(X^*)^{-1} = (-Y)^{1/2}$:

$$f^*(Y) = \left(Y(-Y)^{-1/2}\right) - \left((-Y)^{1/2}\right)$$

Para simplificar el primer término, observamos que $Y = -(-Y)$:

$$\left(Y(-Y)^{-1/2}\right) = \left(-(-Y)(-Y)^{-1/2}\right)$$

Como las matrices conmutan con sus potencias, $(-Y)(-Y)^{-1/2} = (-Y)^{1/2}$:

$$= \left(-(-Y)^{1/2}\right) = -\left((-Y)^{1/2}\right)$$

Ahora combinamos ambos términos:

$$f^*(Y) = \left[-((-Y)^{1/2})\right] - ((-Y)^{1/2})$$

$$f^*(Y) = -2((-Y)^{1/2})$$